Пётр Цыганов

t.me/p1t_tsy | p.tsygan0v@ya.ru |

Education

ШАД Россия, Санкт-Петербург
Data Science *2025 – 2027 (expected)*
НИУ ИТМО Россия, Санкт-Петербург
Бакалавриат: прикладная математика и информатика *2023 – 2027 (expected)*
Relevant coursework: Efficient Deep Learning Systems

Research Experience

Исследование методов управления внутренними состояниями LLM
Исследователь, подготовка научной статьи *Июль 2026 – настоящее время*

- Разрабатываю методы управления поведением современных LLM через интервенции во внутренние recurrent states; провожу эксперименты на Qwen3.5-9B и сравниваю подходы с классическим activation steering.
- Разработал исследовательский pipeline для извлечения и модификации внутренних состояний модели, проведения масштабных экспериментальных sweep'ов, ablation studies и анализа представлений на уровне отдельных слоёв и attention heads.
- Исследую геометрию и динамику внутренних представлений LLM; теоретически анализирую распространение интервенций через recurrent dynamics и экспериментально проверяю полученные предсказания.
- Построил evaluation pipeline для измерения силы steering, устойчивости эффекта и сохранения исходных способностей модели; использую автоматические метрики, IFEval и LLM-as-a-judge, исследую композицию нескольких управляемых свойств.

Experience

Т-Банк Санкт-Петербург / Remote
C++-разработчик, команда систем хранения данных *Июнь 2025 – Ноябрь 2025*

- Разрабатывал компоненты распределённой СУБД на базе PostgreSQL с разделением compute и storage.
- Оптимизировал критический путь записи WAL: исследовал I/O, буферизацию и порядок записи для увеличения throughput и стабильности репликации.
- Реализовал механизм безопасного удаления устаревших WAL с учётом прогресса реплик и требований консистентности распределённой системы.
- Участвовал в разделении storage-компонента на WAL-server и pageserver, позволяющем независимо масштабировать пути записи и чтения.

Projects

Оптимизация CPU-инференса Whisper до real-time

- Профилировал inference pipeline моделей Whisper различных размеров и исследовал pruning, quantization, multitoken prediction и компиляцию через torch.compile и ONNX.
- Исследовал trade-off между качеством распознавания и производительностью, сравнивая оптимизации по Word Error Rate (WER) и real-time factor (RTF).

Skills

Languages: Python, C++, CUDA
Deep Learning: PyTorch, LLM, Transformers, mixed-precision training
Performance: benchmarking, profiling, torch.compile, ONNX
Systems: Linux, Multithreading, I/O, Performance Engineering
Algorithms: Algorithms and Data Structures, Competitive Programming

Achievements

Лучший исследовательский проект на смене "Лето с AIRI" 2026 — steering внутренних состояний LLM
Победитель олимпиад по спортивному программированию ("Высшая проба" и "Технокубок")
Победитель регионального этапа ВСОШ по математике и информатике
Codeforces Expert (pittsy, max rating 1715)